

Reducindo a Incerteza no Mercado de Seguros: Uma Abordagem via Informações de Sensoriamento Remoto e Atuária

VITOR AUGUSTO OZAKI*

ROGÉRIO COSTA CAMPOS[†]

Sumário: 1. Introdução; 2. Sensoriamento Remoto e Aplicações; 3. Método para a Quantificação Local das Perdas Agrícolas; 4. Modelagem Estatística da Produtividade Agrícola; 5. O Mecanismo de Indenização; 6. A Precificação do Risco Agrícola; 7. Fonte de Dados; 8. Resultados e Discussão; 9. Resultados da Análise Espectral; 10. Resultados da Modelagem Estatística e Precificação do Risco; 11. Conclusão.

Palavras-chave: Modelos espaço-temporais; Sensoriamento remoto; Seguro agrícola.

Códigos JEL: Q1.

Em qualquer contrato de seguro, dois parâmetros são fundamentais: a taxa de prêmio e a indenização. A metodologia de cálculo da taxa de prêmio é fundamental para evitar problemas de assimetria de informação, enquanto métodos de acompanhamento do objeto segurado podem ser úteis no dimensionamento e controle das perdas. Em geral, a incerteza do fluxo financeiro das empresas em um mercado contingente é elevada. O estudo propõe reduzir essa incerteza por meio de métodos alternativos de precificação baseados em modelos hierárquicos Bayesianos e no uso de informações de sensoriamento remoto. A metodologia aprimora o entendimento da dinâmica temporal e espacial do fluxo financeiro de um agente econômico no mercado de seguro agrícola considerado um dos ramos mais complexos para se operacionalizar. Os resultados mostram que a metodologia de precificação estima com relativa precisão as taxas de prêmio e o uso da geotecnologia aponta para melhorias significativas na quantificação das perdas agrícolas.

Any insurance contract includes two key parameters: the premium rate and the indemnity. The methodology for calculating the premium rate is fundamental to avoid information asymmetry problems, while methods to monitoring the insured object can be useful to measure and control losses. Usually, uncertainties in relation to the cash flow of companies in a contingent market are high. This study proposes that this uncertainty can be reduced through alternative pricing methods based on Bayesian hierarchical models and geotechnology. The methodology allows for a better understanding of the temporal and spatial dynamic of the cash flow of an economic agent in the crop insurance market in Brazil at municipality level. The results show that fair premium rates can be precisely estimated using the pricing methodology and that geotechnology brings about significant improvements in quantifying crop losses.

*Universidade de São Paulo. Escola Superior de Agricultura Luiz de Queiroz, Departamento de Economia, Administração e Sociologia. Av. Pádua Dias, 11, Agronomia. Piracicaba – SP, 13418-900. E-mail: vitorozaki@gmail.com

†Universidade Federal de Pelotas, Departamento de Matemática e Estatística. E-mail: rogerio.c.campos@hotmail.com



1. INTRODUÇÃO

O sucesso do empreendimento agrícola depende fundamentalmente de fatores que estão fora do controle do produtor rural. O clima é uma das principais variáveis de impacto na produção agrícola. Fatores abióticos adversos podem reduzir drasticamente a produtividade, influenciar na volatilidade dos preços e, em última instância, levar a quedas bruscas do faturamento. São exemplos: seca, excesso de chuva, temperaturas mínimas e máximas extremas.

Dentre esses fatores, a seca é o principal causador de grandes perdas agrícolas, na medida em que afeta centenas de propriedades rurais em uma grande extensão territorial Göpfert et al. (1993). A gestão dos riscos climáticos envolve mecanismos com relações distintas entre risco e retorno. Ao longo dos anos, os produtores administraram seus riscos por meio da diversificação espacial, diversificação de culturas e diversificação intersetorial.

De forma geral, essas estratégias possuem relativa eficiência em reduzir os riscos, mas, ao mesmo tempo, comprometem o retorno esperado do empreendimento. Quase todas as estratégias de gestão de risco estão relacionadas a um maior ou menor *trade off* entre risco e retorno. O produtor pode escolher entre maximizar o retorno dado certo nível de risco, ou minimizar o risco associado ao retorno desejado. Entretanto, os mecanismos baseados no princípio da mutualidade permitem reduzir o risco sem grandes oscilações no retorno esperado. O seguro é o mais conhecido e comercializado nos dias atuais em muitos países e em diferentes setores econômicos. Basicamente, o seguro é um mecanismo pela qual se transfere uma despesa futura e incerta (dano), de valor elevado, por uma despesa antecipada e certa, de valor relativamente menor (prêmio).

No setor agropecuário brasileiro, o seguro comercial em grande escala teve início em 1954, por meio da Companhia Nacional do Seguro Agrícola. A companhia operou durante treze anos e foi encerrada em 1966. Desde então, apenas uma empresa operou o seguro rural, em caráter regional e com cobertura limitada. Nos anos 90, diversas seguradoras tentaram operar no ramo rural, mas sem sucesso.

Dentre os principais problemas enfrentados pelo mercado, o alto preço do seguro era um dos principais entraves que inviabilizava sua massificação entre os produtores rurais. Assim, em 2003, o Governo Federal sancionou a Lei que reduziu o prêmio do seguro incentivando a demanda pelos produtores rurais. Se, pelo lado da demanda, a iniciativa governamental foi eficaz, pelo lado da oferta existe ainda uma série de problemas que pode inibir o desenvolvimento do mercado.

A ausência de informações é um dos principais. Em geral, as seguradoras quantificam e precisam o risco com base em informações individualizadas das unidades seguradas. Por exemplo, no seguro automóvel é necessário que o contratante informe não apenas as características do veículo e seu local de uso, mas que também forneça informações sobre o condutor principal. Com isso, tem-se uma idéia do perfil de risco e o respectivo valor da taxa e o respectivo prêmio. Motoristas com perfil de risco mais alto pagarão mais caro pelo seguro.

No caso do seguro agrícola, a ideia é a mesma. A diferença é que as informações de produtividade agrícola das propriedades rurais são praticamente inexistentes. Nesse contexto, as seguradoras utilizam informações agregadas por municípios provenientes do Instituto Brasileiro de Geografia e Estatística (IBGE). Como consequência, a taxa de prêmio é municipalizada. Em outras palavras, todos os produtores rurais em um mesmo município pagam a mesma taxa de prêmio independente do seu nível tecnológico.

Uma implicação direta desse fato é o aumento considerável do problema da seleção adversa. Ou seja, produtores de baixo risco com alta produtividade serão desencorajados a demandar pelo seguro, pelo fato de considerarem a taxa de prêmio alta em relação ao seu risco. Por outro lado, produtores de alto risco estarão mais propensos a demandar pelo seguro aumentando consideravelmente a probabilidade de que o total de indenizações supere o total de prêmios ganhos. Além disso, o IBGE libera a estimativa de produtividade agrícola municipal defasada em dois anos, ou seja, para o ano de 2011 utiliza-se a estimativa da produtividade até 2009, visto que essa é a última informação liberada pelo Instituto Brasileiro de Geografia e Estatística (IBGE).

Outro agravante refere-se a metodologia atuarial de cálculo da taxa de prêmio do seguro. A precificação do risco está baseada nas séries históricas de produtividade agrícola, que apresentam algumas peculiaridades: presença de tendência (ao longo dos anos, os produtores investiram em tecnologia, aumentando consideravelmente sua produtividade), auto correlação, correlação espacial, heteroscedasticidade e pequeno número de observações nas séries históricas. Os métodos de precificação utilizados pelo mercado em outros ramos raramente se aplicam no caso agrícola. Por isso é necessário utilizar metodologias alternativas de precificação que levem em conta tais peculiaridades (Ozaki et al., 2008a,b).

Nesse contexto, o uso de metodologias inadequadas e a falta de informação impossibilitam a correta precificação do risco pelas seguradoras. Sem a correta precificação, as seguradoras podem estar sub ou superestimando o total ganho em prêmios, ou seja, sua receita. Nos dois casos, há problemas. No primeiro caso, ela perde receita, e no segundo, a seleção adversa se agrava ainda mais.

Se existe incerteza pelo lado das receitas, com relação às despesas ela é ainda maior. No início da safra não se sabe ao certo qual será o percentual de perdas ao longo da safra. O que se sabe ao certo é a responsabilidade total assumida pelo mercado segurador. Em 2009, por exemplo, o capital segurado (responsabilidade) foi de pouco mais de US\$ 4 bilhões. Desse total, o mercado indenizará uma parte correspondente ao percentual de perdas.

Destaca-se que as indenizações estão diretamente relacionadas a redução da produtividade agrícola. Por isso, é fundamental monitorar as lavouras ao longo da safra com o objetivo de antever possíveis perdas (sinistros). Embora os vistoriadores de campo forneçam algumas informações sobre a situação das lavouras, ainda não existe uma metodologia utilizada pelo mercado que forneça informações atualizadas e sistematizadas para grandes extensões territoriais.

Nesse contexto, o estudo propõe o uso de uma ferramenta capaz de fornecer informações sobre a variação espacial detalhada do estado das culturas. O monitoramento da safra será realizado com base no monitoramento da biomassa da cultura da soja em alguns municípios do Estado do Paraná. Relações já estabelecidas entre as variáveis biofísicas associadas ao rendimento da cultura, que podem ser quantificadas com base em imagens de satélite serão utilizadas para mapear a superfície em níveis de rendimento calibrados com base nos levantamentos do Departamento de Economia Rural, da Secretaria de Agricultura e do Abastecimento do Paraná (DERAL/SEAB).

Em última análise, a proposta do estudo é dimensionar o fluxo financeiro do seguro agrícola em uma safra agrícola quantificando entradas e saídas de recursos. O fato é que existe uma grande incerteza no fluxo financeiro das seguradoras. Pelo lado das receitas, as metodologias de precificação são inadequadas e, ademais, a última informação utilizada para os cálculos da taxa de prêmio possui defasagem de dois anos. Pelo lado das despesas, não existe nenhuma informação prévia sobre a magnitude e severidade das perdas que possa auxiliar os gestores públicos e privados em tomar medidas preventivas no contingenciamento de recursos para pagamento de indenizações e planejamento de reguladores de sinistros em campo.

Nesse sentido, as análises de sensoriamento remoto (SR) são uma alternativa para quantificar a extensão espaço-temporal da severidade das perdas e devem passar a prover informações atualmente não disponíveis para determinação dos prejuízos agrícolas. Dessa forma, o estudo propõe estimar o fluxo financeiro de uma operação de seguro agrícola. Considerando a entrada de receitas, o artigo propõe uma metodologia estatística alternativa de precificação do risco que leve em conta uma série de peculiaridades presentes nos dados de produtividade agrícola e o uso de covariáveis que a influenciam. Para o cálculo das despesas, considera-se que os prejuízos sejam quantificados pelo sensoriamento remoto utilizando as imagens de satélite para o entendimento da dinâmica espacial das perdas.

Em um contexto em que o seguro agrícola torna-se a principal ferramenta de gestão de risco rural no país, e de fundamental importância para o sistema nacional de crédito rural, o trabalho contribui para o maior entendimento dos ganhos e perdas em uma operação de seguro agrícola. Até então, a literatura abordava apenas o desenvolvimento de metodologias atuariais de cálculo das taxas de prêmio. No entanto, o sucesso do seguro agrícola depende também da possibilidade de se antecipar possíveis sinistros e prever com antecedência os prejuízos na carteira agrícola.



A estrutura do artigo apresenta oito seções: a primeira mostra o sensoriamento remoto e suas aplicações na agricultura, a segunda define o método para quantificação local das perdas agrícolas e, em seguida, a terceira, quarta e quinta seções detalham a modelagem estatística da produtividade agrícola e a precificação do risco. A sexta seção descreve os dados e a sétima discute os resultados. Por fim, a oitava seção conclui o estudo.

2. SENSORIAMENTO REMOTO E APLICAÇÕES

O sensoriamento remoto propicia a obtenção de informações sobre alvos terrestres sem a necessidade de haver contato físico com os mesmos (Jensen, 2000; Rosa, 1990). Para obter as informações acerca de objetos presentes na superfície terrestre, o sensoriamento remoto utiliza o princípio de que diferentes objetos possuem interações diferenciadas com a radiação proveniente do sol. Por meio da verificação dessas interações, torna-se possível relacioná-las com as condições desses objetos.

Nesse sentido, para detectar, medir e registrar a radiação eletromagnética refletida/emitida pela superfície terrestre utiliza-se o sensor remoto. O sensor é um instrumento que recebe as informações da terra e está acoplado a uma plataforma (p.ex., um satélite). De uma forma geral, um satélite pode conter um ou mais sensores.

Existem várias tipos de satélites em operação. Dentre eles destacam-se: LANDSAT, SPOT, CBERS, IKONOS, QUICKBIRD e NOAA. Os cinco primeiros satélites são destinados ao monitoramento e levantamento dos recursos naturais da superfície, enquanto os satélites NOAA (*National Oceanic & Atmospheric Administration*) fazem parte daqueles destinados principalmente aos estudos climáticos e atmosféricos.

Os valores acumulados pelo sensor são relacionados a uma determinada faixa espectral, conhecida como banda espectral. As bandas espectrais são o resultado da soma de energia em um intervalo no espectro. Normalmente, um sensor pode registrar mais do que uma banda. A imagem gerada pelo sensor fornece informações na forma de uma matriz, sendo que cada célula dessa matriz corresponde a um pixel, a menor unidade da imagem. As imagens geradas têm características próprias do sistema sensor, ou seja, sua própria resolução espacial, temporal e espectral.

A escolha das resoluções depende primariamente dos objetivos do estudo. Em estudos relacionados à agricultura, a resolução espacial depende do nível de detalhe que se pretende observar. Sobretudo busca-se definir a resolução com base na relação entre a resolução efetiva do sensor e o tamanho da área agrícola a ser “resolvida” na cena (Pax-Lenney e Woodcock, 1997). Ressalta-se o fato de que a resolução espacial está ligada à largura da superfície terrestre imageada, denominada campo de visão (*Field of View – FOV*), em cada período orbital do satélite.

Em geral, quanto maior a resolução espacial, menor a área da superfície terrestre individualizada por cada detector para um dado sensor. Consequentemente, menor será a largura da faixa imageada em cada passagem do satélite, que levará mais tempo para fazer o recobrimento total da Terra, implicando numa menor resolução temporal. Em outras palavras, quanto maior a resolução espacial menor será a frequência temporal de captura das imagens, e vice-versa.

As aplicações do sensoriamento remoto podem ser encontradas em diversas áreas. São exemplos: recursos hídricos, agricultura, geologia, uso da terra, monitoramento de ambiental, estatística aplicada, saúde pública e economia (Davis et al., 1993; Navalgund et al., 2007). Nota-se, no entanto, que existem poucos estudos que aplicam o sensoriamento remoto aos problemas relacionados a economia. Henderson et al. (2012) utilizaram dados de sensoriamento remoto para medir o crescimento econômico em níveis globais, além de verificar regiões de maior ou menor crescimento.

Na agricultura, os estudos estão baseados, na sua grande maioria, nos índices de vegetação, que relacionam as informações captadas pelos sensores com a vegetação (Junges et al., 2007). Dois índices conhecidos e vastamente utilizados na literatura são: o Índice de Vegetação por Diferença Normalizada – NDVI (Rouse Jr et al., 1974) e o Índice de Realce da Vegetação – EVI (Huete et al., 2002).

Esses índices podem ser obtidos a partir dos dados do sensor MODIS (*Moderate Resolution Imaging Spectroradiometer*), disponibilizados com uma frequência de dezesseis dias e com uma resolução espacial de 250 metros. De forma geral, pode-se relacionar a produtividade agrícola com os valores acumulados do NDVI ao longo do período de desenvolvimento da planta por meio de modelos estatísticos (Fischer, 1994, Grotens, 1993, Quarmby et al., 1993, Rasmussen, 1992, Wall et al., 2008).

Nos últimos anos, diversos estudos abordaram a relação entre sensoriamento remoto e agricultura. Contribuições científicas recentes incluem estimativas de resoluções temporais ótimas para o monitoramento da vegetação em escala nacional, na região do Mediterrâneo, utilizando informações do sensor MODIS/Terra na resolução de 250 m Alexandridis et al. (2008), o desenvolvimento de um novo índice de vegetação (índice Geral de Referência Unificado da Produtividade – GYURI) (Ferencz et al., 2004), aplicações de modelos agrometeorológicos-espectrais (Melo et al., 2008), relações entre NDVI (NOAA/AVHRR – Advanced Very High Resolution Radiometer), precipitação e o estádio fenológico da cultura (soja e feijão), nos anos de 1996 e 1997, no México (Granados-Ramírez et al., 2004), o estudo das relações (estatísticas) entre o Índice de Saúde da Vegetação, Índice de Condição da Vegetação e Índice de Condição da Temperatura, de 1982 a 2004, do AVHRR (Salazar et al., 2007).

Alguns estudos exploram, de forma mais específica, a relação entre o sensoriamento remoto e a seca nas oscilações da produção agrícola. Murthy et al. (2009) abordam a análise do comportamento dos dados NDVI oriundos de imagens NOAA/AVHRR em anos de seca e em anos normais e seu impacto na produção agrícola. Silleos et al. (2002), elaboraram um sistema de alerta que indica os percentuais de danos à cultura em momentos de estiagem. Vicente-Serrano et al. (2006) estudam o uso de dados NDVI (NOAA/AVHRR) e o índice de seca padronizado (SPI) com o objetivo de gerar um modelo de previsão da produção antes da colheita, e também, verificam a influência das variáveis sobre a produção agrícola, por meio de uma regressão linear múltipla. Wall et al. (2008) analisam o poder preditivo do NDVI e do índice de umidade cumulativo (CMI) durante a safra.

No Brasil, um dos primeiros estudos utilizando sensoriamento remoto aplicado ao monitoramento das fazendas foi realizado em 1986, pelo Instituto Nacional de Pesquisas Espaciais (INPE). O objetivo do projeto foi desenvolver uma ferramenta auxiliar no processo de fiscalização do crédito agrícola em cinco municípios paulistas para as culturas de soja, trigo e cana-de-açúcar. Ao todo, 772 propriedades rurais foram mapeadas. O resultado final foi uma série de transparências com os limites das propriedades que puderam ser superpostas às imagens de satélite e, dessa forma, deu-se início à fiscalização das lavouras para fins de crédito agrícola do Banco do Brasil (Duarte, 1988).

Nesse período, outro estudo utilizando sensoriamente remoto estimou a produtividade do trigo no sudoeste paulista utilizando um modelo agrometeorológico e o índice de vegetação RVI. A produtividade agrícola foi estimada por um modelo de regressão múltipla tendo como covariáveis o RVI e a produtividade estimada pelo modelo agrometeorológico. Os resultados sugeriram que a incorporação dos dados espectrais no modelo de regressão melhorou significativamente a estimativa da produtividade em nível de propriedade rural (Rudorff e Batista, 1989).

Com o passar dos anos, o desenvolvimento tecnológico (novos sensores e o aumento da capacidade de processamento computacional) possibilitou a obtenção de resultados mais precisos e a operacionalização em larga escala do sensoriamento remoto em inúmeras aplicações. Particularmente, no universo do mercado segurador agropecuário, as geotecnologias podem ser aplicadas tanto no georreferenciamento das propriedades agrícolas como no mapeamento atualizado das lavouras, em um nível de detalhamento muito superior aos estudos supracitados.

Em outras palavras, o uso conjunto das imagens de satélite, do sistema global de posicionamento (GPS) e dos sistemas de informação geográfica (SIG) pode gerar uma grande quantidade de informações que poderão ser utilizadas pelas seguradoras e instituições bancárias (Macedo e Rudorff, 2003).

Uma aplicação direta desses resultados consiste em antecipar as frustrações de safra e, com isso, dimensionar com maior precisão o contingente de reguladores de sinistro e provisões de recursos nas seguradoras. Ressalta-se o fato de que a ocorrência de uma estiagem severa pode afetar uma grande



quantidade de propriedades rurais em uma grande extensão territorial, dificultando sobremaneira a quantificação das perdas pelos reguladores no prazo máximo permitido pela legislação (trinta dias).

3. MÉTODO PARA A QUANTIFICAÇÃO LOCAL DAS PERDAS AGRÍCOLAS

Pelo exposto acima fica evidente que a probabilidade de ocorrer determinado nível de perda de rendimento em uma dada localização é uma informação importante para estruturar as políticas de seguro agrícola. Modelos agrometeorológicos e estatísticos alimentados por variáveis meteorológicas obtidas de estações de superfície têm sido utilizados para modelar a variabilidade espacial de rendimento.

Uma séria limitação no uso dessa abordagem ocorre em função da necessidade de se fazer interpolações espaciais a partir de dados pontuais de estações de superfície. Nesse cenário, a correlação espacial das variáveis é pouco conhecida e, como consequência, ao se adotar índices climáticos como indicativo da ocorrência de sinistros, não se faz distinção entre os diferentes níveis de perda de rendimento dentro de um agregado espacial que pode ser variar consideravelmente.

Uma alternativa para estratificar o espaço agrícola em diferentes níveis de rendimento é a utilização de dados de sensoriamento remoto (SR). Imagens adquiridas por sensores em diferentes plataformas (áreas e orbitais) possibilitam obter informações sobre o estado das culturas na resolução espacial do sensor utilizado. Como consequência, o espaço pode ser mapeado para o grau de risco em um dado momento e a perda de rendimento pode ser espacialmente desagregada e monitorada em localidades específicas.

Diversas relações biofísicas entre dados de SR e variáveis relacionadas ao rendimento das culturas são empregadas para quantificar a potencial perda de rendimento em uma dada localidade. A mais usual é explorar a relação entre as imagens de SR e a biomassa das culturas agrícolas. No senso mais comum, as imagens multiespectrais da superfície são obtidas (ao longo do ciclo agrícola) a partir de plataformas orbitais e, principalmente, as bandas espectrais posicionadas na região do vermelho (B660nm, sensibilidade à eficiência da fotossíntese) e do infravermelho próximo (B820 nm, sensibilidade ao acúmulo da biomassa) são utilizadas para o cálculo de índices espectrais (e.g. *Normalized Difference Vegetation Index* – NDVI e *Simple Ratio* – SR) relacionados ao vigor vegetativo (Nemani et al., 1993).

Nesse estudo foram utilizadas imagens do sensor MODIS para quantificar a biomassa acumulada ao longo do ciclo da cultura da soja. Em uma primeira etapa, os municípios estudados foram mapeados com base em critérios de diferenciação espectro-temporal de alvos em uma série temporal de imagens MODIS do ano safra 2007/2008. Desse processo resultou um mapeamento que dividiu a área dos municípios nas classes (i) área agrícola (não soja), (ii) área de soja e (iii) área não agrícola. Na fase seguinte, as imagens de reflectância foram utilizadas para gerar uma série de imagens NDVI ($\frac{B820 - B660}{B820 + B660}$) na qual a biomassa pôde ser extraída com base no acúmulado do índice ao longo do ano agrícola 2008/2009.

Em função dos objetivos do estudo, os dados de rendimento levantados pelo DERAL foram relacionados aos dados de biomassa por meio de um modelo de regressão linear. As médias espaciais de biomassa e a produtividade agrícola por unidade regional do DERAL foram utilizadas para o ajuste da regressão. Finalmente, mapas de classes de rendimento foram calculados para diferentes níveis de produtividade segurada.

Em outras palavras, uma vez que a biomassa foi determinada para cada pixel nas respectivas áreas de soja, o passo seguinte consistiu em uma análise estatística entre a média da biomassa de todos os pixels pertencentes a um município com a produtividade agrícola média do respectivo município liberada pelo DERAL. A análise foi realizada por meio de um modelo de regressão linear dado por $y_i = \alpha_1 + \alpha_2 x_i + \varepsilon_i$, em que ε é o ruído, $\varepsilon \sim N(0, \sigma^2)$, a variável resposta y é a produtividade agrícola, a variável explanatória x é a biomassa e o subscrito i representa o município. O modelo ajustado foi utilizado para estimar a produtividade agrícola tendo como base os valores da biomassa em cada pixel. Dessa forma, foram estimados de produtividade agrícola em todos os pixels correspondentes à cultura da soja.

Todos os valores de produtividade estimados foram comparados a cada nível de produtividade garantida, dada pela multiplicação dos níveis de cobertura (50, 55, 60, 65, 70%) pela média dos últimos cinco anos anteriores a 2009. Optou-se pela média dos últimos cinco anos por ser este o período comumente utilizado pelas seguradoras para o cálculo da produtividade garantida.

O cálculo do índice de perda foi feito com base nas produtividades estimadas e garantidas. Considera-se que houve perda toda vez que a produtividade estimada, em cada pixel, foi menor do que a garantida. Nesse caso, supõe-se que a perda é total, ou seja, não há perda parcial. O resultado é um percentual da área total de soja plantada no município em que houve perda para os diferentes níveis de cobertura.

4. MODELAGEM ESTATÍSTICA DA PRODUTIVIDADE AGRÍCOLA

A modelagem estatística dos dados de produtividade agrícola é um tema amplamente explorado pelos economistas, em função de sua importância na administração de risco e seguro agrícola. Em diversos países, as séries históricas de produtividade são curtas e apresentam problemas de ordem metodológica, tais como presença de tendência (determinística e estocástica) (Anibal, 1989), variância não-constante (Yang et al., 1992, Kapiamba, 2005) e dependência temporal e espacial nos dados (Goodwin e Ker, 1998).

A precificação do risco envolve a estimativa da probabilidade de perda, que está diretamente relacionada com a suposição da forma da distribuição de probabilidade. Particularmente, o interesse está na calda esquerda da distribuição. Nesse contexto, a suposição de que a distribuição seja simétrica pode ser equivocada no contexto do seguro agrícola. Assimetrias e bimodalidade podem alterar consideravelmente a probabilidade de perda e a taxa de prêmio (Ozaki e Silva, 2009).

Na literatura, algumas pesquisas apontam que a suposição de normalidade não pode ser rejeitada (Anibal, 1989, Just e Weninger, 1999). A normalidade pode ser explicada por diferenças entre as culturas agrícolas e/ou regiões, método utilizado para retirar a tendência e os testes estatísticos utilizados (Harri et al., 2008).

Outros encontraram evidências contra a normalidade (Day, 1965, Taylor, 1990, Ramírez, 1997, Ramírez et al., 2003a,b, Atwood et al., 2002, 2003). Alguns desses trabalhos sugerem o uso de diferentes distribuições, como, por exemplo, a distribuição Beta (Nelson e Preckel, 1989), Gama (Gallagher, 1987) e a família Johnson Su (Moss e Shonkwiler, 1993, Ramírez et al., 2003a,b).

Os estudos ainda diferem quanto ao tipo de abordagem estatística: paramétrica (Chen e Miranda, 2004), semi-paramétrica (Ker e Coble, 2003), não-paramétrica (Goodwin e Ker, 1998, Turvey e Zhao, 1999, Ozaki et al., 2008b), o método Bayes empírico não-paramétrico (Ker e Goodwin, 2000), a abordagem Bayesiana espaço-temporal (Ozaki et al., 2008a, Ozaki e Silva, 2009). Alguns estudos ainda comparam ajustes de distribuições e discutem suas implicações para o seguro agrícola (Sherrick et al., 2004, Norwood et al., 2004, Ramírez e McDonald, 2006, Norwood et al., 2006).

A escolha de um modelo estatístico que melhor reflita a densidade condicional da produtividade é um fator importante no cálculo atuarial. Apesar do ajuste das distribuições ser um ponto controverso na literatura, nesse trabalho a suposição de normalidade será utilizada na modelagem dos dados de produtividade. O foco está em se modelar o processo gerador dos dados da produtividade agrícola média.

Em diversos trabalhos empíricos, a única informação conhecida no momento t é o próprio tempo. Nesse contexto a densidade condicional é baseada apenas no processo temporal dos dados. Nota-se, no entanto, que os dados de produtividade agrícola seguem também um processo espacial que deve ser levado em conta (Ker e Goodwin, 2000, Ozaki et al., 2008a,b).

Uma situação desfavorável para as seguradoras ocorre quando eventos climáticos adversos atingem produtores rurais. Em outras palavras, quando ocorre uma seca, por exemplo, este fenômeno não afeta apenas um único produtor, mas muitos produtores em uma vasta extensão territorial.

Este fenômeno é conhecido como risco sistêmico ou risco de evento generalizado. Dentro do contexto do mercado de seguros, o risco sistêmico é um dos maiores problemas enfrentados pelas segurado-



ras privadas, no ramo rural (Miranda e Glauber, 1997). O risco sistêmico está diretamente relacionado com a presença de correlação espacial entre as unidades seguradas. Nesse caso, a extensão territorial dos danos pode ser detectada através do semivariograma, ou seja, uma função matemática que relaciona a correlação e a distância.

Goodwin (2001) estimou o decaimento da correlação espacial para anos normais e anos com incidência de seca nos EUA. No primeiro caso, a correlação espacial se reduz mais rapidamente com o aumento da distância, estabilizando-se no valor de 0,10 quando a distância entre as áreas consideradas é de aproximadamente 322 km. Considerando anos em que secas ocorreram, a medida de correlação decresceu mais vagarosamente, atingindo o mesmo nível de 0,10 a uma distância de 644 km, levando à conclusão de que em anos de ocorrência de eventos generalizados o problema do risco sistêmico é mais acentuado do que em anos normais.

Wang e Zhang (2003) utilizaram correlogramas para a determinação da estrutura de dependência espacial. O estudo mostrou que a distância máxima estimada para a correlação não negativa foi de 917 km. O estudo também leva em conta a tendência nas séries de produtividade agrícola. Desta forma, percebe-se que na maioria das vezes o processo gerador dos dados de produtividade não é constante ou estável, mas varia com o tempo.

A incorporação de novas tecnologias e métodos mais adequados de manejo permitiu ao produtor elevar sua produtividade com o passar do tempo. Assim, a produtividade observada em meados de 1980 não pode ser comparada com a produtividade em 2011, por exemplo. Para que tais produtividades sejam comparáveis é preciso que a componente de tendência seja retirada da série. Diversos métodos são utilizados na literatura para remover a tendência: lineares ou não-lineares, como, por exemplo, modelos autoregressivos-média móvel, alisamento não-paramétrico local, *splines* e regressão robusta (Woodard e Garcia, 2008, Swinton e King, 1991, Just e Weninger, 1999, Ramírez et al., 2003b, Finger, 2010).

Outro ponto importante na modelagem da produtividade é o pequeno número de observações em nível municipal, que é menor ainda em nível de propriedade rural. A escassez de uma série temporal relativamente longa impossibilita detectar variações estruturais na produtividade e, consequentemente, verificar a ocorrência de eventos catastróficos no decorrer da série.

Em alguns países, como, por exemplo, nos EUA, a série de produtividade agrícola regional gerada pelo órgão responsável (*National Agricultural Statistics Service – NASS*) abrange o período de 1962-2010 para a maioria das culturas. Apesar de alguns métodos terem sido sugeridos para tentar superar tal problema, tais como combinar dados de produtividade individuais e regionais ou utilizar dados agregados como *proxies* para os dados em nível de fazenda, ainda assim isto dificulta sobremaneira o trabalho de modelar a estrutura de risco do produtor de maneira acurada.

5. O MECANISMO DE INDENIZAÇÃO

O seguro analisado indeniza o segurado pelo total gasto no custeio rural, ou seja, o limite máximo de garantia é o total despendido em financiamento para o início da safra. A indenização baseia-se na produtividade agrícola (em quilogramas por hectare ou sacas por hectare), para cada propriedade agrícola I_i , que pode ser expressa da seguinte forma:

$$I_i = \phi_i \max[(y_i^c - y_i), 0] \quad (1)$$

Em que:

- ϕ_i é a dedutibilidade, $0 < \phi_i < 1$;
- y_i^c é o nível de produtividade crítica ou garantida;
- y_i é a produtividade observada.

A produtividade crítica é descrita de acordo com a equação: $y_c = \alpha_i \mu_i$, em que α_i é o nível de cobertura escolhido pelo produtor, $0 < \alpha_i < 1$, e μ é a produtividade esperada do produtor. Se a produtividade agrícola no final de determinado período for menor do que a produtividade garantida escolhida pelo produtor y_i^c , então o segurado será indenizado. Seu valor é igual à diferença entre a produtividade garantida e a produtividade efetiva multiplicada por um preço. Para isso, o segurado deve pagar um prêmio e obedecer a determinadas requisições nas condições gerais do seguro.

O prêmio de seguro é o preço relativo ao risco negociado entre a seguradora e o produtor rural. Normalmente, a taxa de prêmio é calculada com base no histórico de perdas e no perfil de risco de cada segurado. Mas para isso é fundamental que exista uma série histórica relativamente longa e consistente de dados individualizados.

No caso do seguro agrícola, em função da inexistência de dados massificados de produtividade agrícola em nível de propriedade, as seguradoras utilizam os dados municipalizados do Instituto Brasileiro de Geografia e Estatística (IBGE) ou no caso do Paraná, os dados do Departamento de Economia Rural, da Secretaria de Agricultura e do Abastecimento do Paraná (DERAL/SEAB). Como consequência, a precificação é realizada com base nos municípios, gerando, dessa forma, taxas municipalizadas.

Esse fato cria um problema para o mercado. Em um programa de seguro facultativo, um produtor que possui um histórico de produtividade que em média é maior do que a média dos produtores de sua região ou município possivelmente não demandaria pelo seguro pagando o mesmo prêmio que um produtor que possui um histórico de produtividade inferior. A solução encontrada pelo Governo Federal foi tornar o seguro compulsório, ou seja, quando o produtor realiza o pedido de crédito rural automaticamente é atrelado o seguro agrícola. Nesse contexto, a estimativa precisa da taxa de prêmio é fundamental para os produtores que serão obrigados a demandar pelo seguro quando solicitarem recursos do Sistema Nacional de Crédito Rural.

6. A PRECIFICAÇÃO DO RISCO AGRÍCOLA

A escolha de um modelo estatístico que melhor reflita a densidade da produtividade condicional é um fator importante no cálculo atuarial da taxa de prêmio. Para isso, deve-se destacar o processo gerador dos dados no momento de se modelar a produtividade agrícola (Goodwin e Ker, 1998).

Em diversos trabalhos empíricos, a única informação conhecida no momento t é o próprio tempo. Desta forma, nestas análises, a densidade condicional é baseada apenas no processo temporal gerador dos dados. Nesse estudo, incorporou-se o aspecto temporal e espacial do processo gerador dos dados, levando-se em conta os municípios vizinhos.

A modelagem da produtividade tem por objetivo prever a produtividade dois passos a frente. Porém, o fato de a série temporal estudada ser relativamente curta criou dificuldades adicionais no tocante à previsão. Isso porque o IBGE libera os dados com dois anos de defasagem. A última observação liberada pelo IBGE foi relativa ao ano de 2009. Desta forma, tentou-se ajustar um modelo que pudesse prever a produtividade nos dois anos seguintes.

Para atingir tal objetivo, optou-se por modelar a estrutura de média e deixar que a precisão permanesse constante ao longo da análise. Gelfand et al. (1998) apontam que modelar o componente de média para problemas de previsão resulta em maior efetividade.

Deste modo, considerando a média μ_{it} como sendo idêntica a $E(Y_{it})$, onde i representa o indexador da variável espacial e t a variável temporal, tal que $i = 1, 2, \dots, S$, $t = 1, 2, \dots, T$ e Y_{it} representa a produtividade no município i no tempo t .

O objetivo será modelar a média, de tal forma que μ_{it} reflita, de forma geral, as covariáveis, o efeito temporal, a variação espacial da produtividade agrícola além do efeito espaço-temporal. Por meio dos modelos hierárquicos a estrutura de dependência entre os parâmetros pode ser captada através da distribuição de probabilidade conjunta. A possibilidade de se modelar a estrutura de dependência



através de modelos hierárquicos é bastante intuitiva e facilita a visualização de cada componente na análise ao invés de modelar tal estrutura diretamente através de y_{it} .

Na notação usual, os modelos hierárquicos são determinados por estágios. Se y_{it} for considerado como condicionalmente independente em relação a μ_{it} , então os parâmetros adicionados a μ_{it} serão aleatórios. Sendo assim, se um efeito aleatório indexado por t for adicionado a μ_{it} , então, marginalmente, y_{it} refletirá a dependência temporal no decorrer de certo ano. O mesmo ocorre com um efeito indexado por i , ou seja, marginalmente, y_{it} refletirá a dependência espacial dentro de certa localidade.

Ao todo, foram ajustados dezoito modelos, desde o modelo mais simples, com apenas uma constante, até modelos mais complexos. De forma geral, a modelagem baseia-se em uma estrutura temporal ζ_t para a média do processo com a componente espacial sendo captada nas distribuições a priori.

A estrutura temporal completa é dada por:

$$\zeta_t = \sum_{j=1}^p \rho_j y_{t-j} + \sum_{m=0}^b \beta_m t_m + \sum_{n=1}^k \delta_n x_{nt} + \varepsilon_t \quad (2)$$

Em que, $\varepsilon_t \stackrel{iid}{\sim} N(0, \sigma^2)$, $-1 \leq \rho_j \leq 1$, e x são séries múltiplas de entrada.

Na parte determinística do modelo (2), optou-se por trabalhar com a variável t centrada para acelerar a convergência dos algoritmos Monte Carlo Markov Chain (MCMC). Desta forma, centrando t , têm-se que $t^* = (t - (N+1)*0.5)$. Considerou-se $p = 1$, $b = 2$ e $k = 1$ no ajuste dos modelos.

Algumas considerações quanto aos modelos de tendência estocástica devem ser colocadas. Primeiro, o parâmetro de correlação ρ foi permitido variar de acordo com a área e, segundo, uma priori permutável Normal foi atribuída ao parâmetro ρ com hiper-distribuições Normal e Inversa Gama, respectivamente, para os parâmetros de média e variância.

Distribuições a priori não-informativas foram designadas para β considerando a distribuição Normal com o parâmetro de precisão $\tau \rightarrow 0$. Se considerarmos um modelo de efeitos aleatórios, então todos os parâmetros β 's serão permutáveis, de modo que seria conveniente e razoável supor que embora os parâmetros possam ser diferentes um do outro, são provenientes da mesma distribuição populacional.

O modelo (2) capta a tendência e autocorrelação presente nos dados de produtividade. Além do processo temporal, é importante modelar o processo espacial. O comportamento da produtividade em municípios vizinhos tende a oscilar na mesma direção quando ocorre um fenômeno climático adverso, como, por exemplo, a seca. Nesse contexto, a produtividade segue um processo espaço-temporal (Ker e Goodwin, 2000).

De forma geral, a modelagem espacial pode conter covariáveis espaciais representando determinadas características de um local (Besag, 1974, Clayton e Kaldor, 1987, Cressie e Chan, 1989, Besag et al., 1991, Bernardinelli et al., 1995). Na ausência de covariáveis espaciais, as variáveis estruturadas espacialmente η_i podem captar o efeito espacial considerando a natureza geográfica de cada região. Por sua vez, as variáveis não-estruturadas espacialmente podem captar a heterogeneidade entre certas regiões, como, por exemplo, o efeito de variáveis socioeconômicas (Gelfand et al., 1998).

A identificabilidade, neste caso, é verificada no modelo hierárquico atribuindo-se distribuições a priori condicionais auto-regressivas (CAR) para as variáveis estruturadas espacialmente e distribuições a priori permutáveis para a variável não-estruturada espacialmente (Bernardinelli et al., 1995, Dreassi, 2003, Waller et al., 1997).

As variáveis estruturadas e não-estruturadas espacialmente foram incluídas no modelo (2), tal que o modelo espaço-temporal pode ser representado por:

$$\zeta_{i,t} = \sum_{j=1}^p \rho_{i,j} y_{i,t-j} + \sum_{m=0}^b \beta_{i,m} t_m + \sum_{n=1}^k \delta_{i,n} x_{nt} + \eta_{i,t} + \gamma_{i,t} + \varepsilon_{i,t} \quad (3)$$

Utilizando-se do princípio da parcimônia, modelos mais simples foram considerados ao longo do trabalho. Nota-se que, devido à permutabilidade condicional dado o tempo, a distribuição a priori re-

sultante pode ser representada por $\gamma_{i,t} \xrightarrow{iid} N(\mu_{i,t}^\gamma, \sigma^2(\gamma))$. Considerou-se para o efeito espacial $\eta_{i,t}$ no i -ésimo município, no ano t , distribuição a priori Condisional Autoregressiva (CAR). Assim, $\eta_{i,t} \sim N(\mu_{i,t}^\eta, \sigma^2(\eta)/n_t)$, onde $\mu_{i,t}^\eta$ é a média dos j -ésimos municípios adjacentes ao município i . Como hiper-prioris para $\sigma^2(\gamma)$ e $\sigma^2(\eta)$, foram consideradas as distribuições Gama Inversa.

Tendo em vista que o objetivo da modelagem é a previsão da produtividade, deve-se escolher um critério de escolha de modelos que possa acomodar modelos hierárquicos com efeitos aleatórios em que a dimensão é difícil de se caracterizar. Além disso, em modelos sofisticados a dimensão do modelo aumenta com o tamanho da amostra, invalidando o uso de critérios de seleção de modelos mais conhecidos e utilizados na literatura, tais como *Akaike Information Criteria* (AIC) e *Bayesian Information Criteria* (BIC). Conforme destacam Carlin e Louis (2000), o uso de prioris impróprias resulta em distribuições preditivas condicionais impróprias, limitando também o uso do fator de Bayes. Critérios baseados em validação cruzada também são de difícil aplicação para modelos mais sofisticados devido à inclusão de variáveis latentes que são definidas somente pela priori.

Nesse contexto, os critérios baseados em densidades preditivas são considerados para a escolha dos modelos Laud e Ibrahim (1995). Esses critérios são de fácil interpretação, não são baseados em pressuposições assintóticas e permitem a incorporação de distribuições a priori. Intuitivamente, pode-se dizer que bons modelos devem realizar previsões próximas ao que foi observado em experimentos idênticos.

O objetivo é minimizar a perda preditiva a posteriori, denominada erro predito quadrático Gelfand e Ghosh (1998). A distribuição preditiva a posteriori é mostrada abaixo:

$$f(x_{new}|x_{obs}) = \int f(x_{new}|M)p(M|x_{obs})dM \quad (4)$$

onde M representa o conjunto de todos os parâmetros em certo modelo e x_{new} é a réplica do vetor de dados observados x_{obs} .

O critério de seleção de modelos é baseada em uma função de discrepância $d(x_{new}, x_{obs})$, sendo que o objetivo é escolher aquele que minimiza a esperança da função de discrepância, condicional a x_{obs} e M_q , onde o subscrito q representa todos os parâmetros em determinado modelo q . Para modelos Gaussianos, a função de discrepância é dada por $d(x_{new}, x_{obs}) = (x_{new} - x_{obs})^T(x_{new} - x_{obs}) \in D_m$ por:

$$D_{M_i} = \sum_n E [(x_{n,obs} - x_{n,new})^2 | x_{obs}, M_i] \quad (5)$$

Os autores demonstraram que $D_{M_i}^n$ pode ser fatorada em dois termos aditivos G_{M_i} e P_{M_i} , onde o primeiro $G_{M_i} = \sum_n [(x_{n,obs} - E(x_{n,new}|x_{obs}))^2]$ representa a soma de quadrado dos erros, ou seja, uma medida de qualidade de ajuste, e o segundo $P_{M_i} = \sum_n \text{var}(x_{n,new}|x_{obs})$ um termo de penalização.

Após o ajuste, seleção do modelo e previsão da produtividade dois passos à frente, o próximo passo consiste em especificar o risco. Desta forma, a taxa de prêmio (PR) será calculada levando-se em conta certo percentual α , tal que $0 \leq \alpha \leq 1$ da produtividade esperada y^e dada por:

$$\text{Taxa de Prêmio}(PR) = \frac{F_Y(\lambda y^e)E_Y[\lambda y^e - (Y|y < \lambda y^e)]}{\lambda y^e} \quad (6)$$

Em que E é o operador de esperança e F a distribuição cumulativa da produtividade (Goodwin e Ker, 1998). No contexto Bayesiano, a taxa de prêmio pode ser derivada diretamente do modelo (Ozaki et al., 2008a,b).

Se y for reparametrizado, de forma que, $y^* = y/\lambda y^e$, então a Eq. (6) será:

$$PR = P(y^* < 1)E_{y^*}[1 - (y^*|y^* < 1)] \quad (7)$$



Após algumas simplificações, a equação da taxa de prêmio se reduz a Eq. (8):

$$PR = \int w f(w) dw \quad (8)$$

Em que, $w = 1 - y^*$ e $PR = E[wI(0 < w < 1)]$. Nota-se que, em função da mudança de variável, o suporte também mudou, de forma que w se situa entre 0 e 1.

7. FONTE DE DADOS

As informações espaciais utilizadas no mapeamento das áreas de soja foram imagens LANDSAT/TM 5. As imagens foram previamente registradas utilizando como base o produto GEOCOVER fornecido pela NASA. O mapeamento foi desenvolvido utilizando o software SPRING, disponibilizado gratuitamente pelo INPE.

Para a precificação do risco utilizou-se a produtividade agrícola em quilogramas por hectare, provenientes do Instituto Brasileiro de Geografia e Estatística (IBGE), do período de 1997 a 2009. As informações de precipitação acumulada são provenientes da Agência Nacional de Águas (ANA), da segunda quinzena de janeiro à primeira quinzena de março, período crítico para a soja na região de estudo. Os dados de custeio agrícola por município foram obtidos junto ao Banco Central, em milhões de reais, para o ano safra 2008/09.

A região de estudo compreende doze municípios do estado do Paraná em cinza escuro (Fig. 1). Os municípios em cinza claro representam os municípios vizinhos utilizados para construir a estrutura de vizinhança da modelagem estatística.

Em particular, os municípios analisados são: C1 – Assis Chateaubriand; C2 – Formosa do Oeste; C3 – Iracema do Oeste; C4 – Jesuítas; C5 – Juranda; C6 – Maripá; C7 – Nova Aurora; C8 – Palotina; C9 – Quarto Centenário; C10 – Rancho Alegre do Oeste; C11 – Tupãssi; C12 – Ubiratã. Os municípios vizinhos são: Terra Roxa, Francisco Alves, Iporã, Brasilândia do Sul, Alto Piquiri, Mariluz, Goioerê, Janiópolis, Boa Esperança, Mamborê, Campina da Lagoa, Braganey, Iguatu, Anahy, Corbélia, Cafelândia, Cascavel, Toledo e Nova Santa Rosa.

Na safra 08/09, o estado do Paraná foi o segundo maior produtor de soja com, aproximadamente, 17% do total produzido no país. Os municípios selecionados no estudo respondem por quase 20% de toda a soja produzida no estado com quase 1,9 milhões de toneladas.

8. RESULTADOS E DISCUSSÃO

Os resultados serão mostrados em duas partes: a primeira referente à análise espectral que resultou na quantificação das perdas na safra 2008/09, por município, e a segunda à precificação do risco utilizando a abordagem espaço-temporal.

Antes da discussão, porém, é importante ressaltar as suposições associadas à modelagem: i) em cada município, considerou-se que todas as fazendas estão seguradas; ii) em caso de sinistro, existe apenas a situação de perda total (não há perda parcial); iii) as taxas são estabelecidas para cada município, ou seja, todos os produtores em um mesmo município pagam a mesma taxa de prêmio; iv) a franquia dedutível é igual a zero; v) a taxa de prêmio é atuarialmente justa, ou seja, é igual à indenização esperada (não há inclusão dos custos administrativos, operacionais e lucro).

9. RESULTADOS DA ANÁLISE ESPECTRAL

As tabelas 1 a 5 mostram os percentuais das áreas de cada município em que a produtividade agrícola foi menor do que a produtividade garantida nos níveis de cobertura de 50, 55, 60, 65 e 70%. Por exemplo,

Figura 1: Municípios selecionados para o estudo.

Fonte: Elaborado pelos autores.

na tabela 1, ao nível de cobertura de 50%, o município C8 apresentou um percentual de perdas de 44,9% em relação ao total plantado no município.

Como se supõe que todas as fazendas no município estão seguradas e que ocorrem apenas perdas totais, o percentual de perda revela o percentual das áreas em que a produtividade estimada foi menor do que a produtividade garantida. Assim, para o município C8, quase 45% da área plantada apresentou perda total. Por outro lado, não houve perda em 39,4% da área. A área restante corresponde a áreas não cobertas por soja no município.

Os resultados mostram que, como esperado, quanto maior o nível de cobertura, maior o índice de perda. Todos os municípios apresentam perdas maiores do que 10%. Ao nível de 70% de cobertura, o município com maior percentual de perda foi C1 (Assis Chateaubriand), com pouco mais de 70%, seguido dos municípios C6 (Maripá) e C8 (Palotina), respectivamente. Esses resultados evidenciam o fenômeno do risco sistêmico entre municípios, visto que os três municípios são vizinhos (oeste da região analisada).

O percentual da área total sem quebra representa o total da área plantada que não apresentou redução da produtividade abaixo da cobertura. O restante da área não possui soja. A figura 2 ilustra a queda de rendimento na região.

Os mapas de queda de produtividade fornecem uma visão mais precisa das regiões de prejuízo. Em todos os níveis de cobertura, nota-se claramente que a região oeste foi a mais afetada, em função de baixos índices de precipitação e umidade, e temperatura média elevada. No centro e na região leste, ocorreram perdas, mas em geral, a soja se desenvolveu e houve boa produtividade.

Os resultados seguem a tendência do estado do Paraná de elevada redução da produtividade. Dados do Ministério da Agricultura, Pecuária e Abastecimento revelam que o índice de sinistralidade (divisão

**Tabela 1:** Percentual da área com redução de rendimento ao nível de cobertura de 50%.

Município	% Área total COM quebra	% Área total SEM quebra
C1	48,0	41,9
C2	17,7	42,7
C3	11,1	65,8
C4	17,8	40,5
C5	14,4	71,3
C6	46,3	40,0
C7	21,5	55,5
C8	44,9	39,4
C9	11,0	70,3
C10	16,8	67,6
C11	16,0	78,2
C12	13,7	60,0

Fonte: Resultados da pesquisa.

Tabela 2: Percentual da área com redução de rendimento ao nível de cobertura de 55%.

Município	% Área total COM quebra	% Área total SEM quebra
C1	55	35
C2	21,6	38,8
C3	15,1	61,9
C4	20,9	37,3
C5	18,2	67,6
C6	52,8	33,5
C7	26	51
C8	51,5	32,7
C9	14,6	66,6
C10	21,5	62,9
C11	20,7	73,5
C12	18,2	55,4

Fonte: Resultados da pesquisa.

Tabela 3: Percentual da área com redução de rendimento ao nível de cobertura de 60%.

Município	% Área total COM quebra	% Área total SEM quebra
C1	61,3	28,7
C2	25,1	35,3
C3	18,7	58,3
C4	24,4	33,9
C5	22	63,8
C6	58,6	27,7
C7	31,2	45,8
C8	57,1	27,1
C9	19	62,3
C10	25,9	58,5
C11	26,7	67,5
C12	23,3	50,3

Fonte: Resultados da pesquisa.

Tabela 4: Percentual da área com redução de rendimento ao nível de cobertura de 65%.

Município	% Área total COM quebra	% Área total SEM quebra
C1	66,5	23,5
C2	28,8	31,6
C3	22,4	54,6
C4	27	31,3
C5	25,8	59,9
C6	63,9	22,4
C7	36,5	40,5
C8	62,5	21,7
C9	23,9	57,3
C10	31,7	52,8
C11	33	61,2
C12	29,1	44,5

Fonte: Resultados da pesquisa.

**Tabela 5:** Percentual da área com redução de rendimento ao nível de cobertura de 70%.

Município	% Área total COM quebra	% Área total SEM quebra
C1	71,4	18,6
C2	32,6	27,8
C3	25,8	51,2
C4	30,1	28,2
C5	29,9	55,9
C6	68,6	17,7
C7	41,7	35,3
C8	66,5	17,7
C9	28,9	52,3
C10	36,4	48
C11	38,7	55,5
C12	34,8	38,9

Fonte: Resultados da pesquisa.

do total de prêmios arrecadados pelo total de indenizações pagas) do estado foi da ordem de 0,41, sendo que a soja foi uma das maiores responsáveis pelo resultado negativo, visto que quase 65% da contratação do seguro agrícola no estado foi devido a cultura da soja.

Ademais, observa-se certa similaridade entre a estimativa de perdas realizada pelo governo e pelo estudo. Enquanto a redução da produção (em toneladas) estimada pelo governo, segundo Hubner (2009), foi da ordem de 45,1% para a região, os resultados do estudo sugerem que o nível médio de perdas para os municípios selecionados foi de 42,1% considerando o nível máximo de cobertura.

10. RESULTADOS DA MODELAGEM ESTATÍSTICA E PRECIFICAÇÃO DO RISCO

Dentre todos os modelos propostos, o modelo que melhor se ajustou aos dados é dado por:

$$\begin{aligned} y_{i,t} &\sim N(\mu_{i,t}, \tau) \\ \mu_{i,t} &= \rho_i y_{i,t-1} + \beta_{1i} + \beta_{2i} t^* + \delta_{1i} x_{i,t} + \varepsilon_{i,t} \end{aligned} \quad (9)$$

Com distribuições a priori dadas por: $\rho_i \sim (N(\mu^\rho, \tau^\rho), \beta_{1i} = \varphi_{1i} + \nu_1, \beta_{2i} = \varphi_{2i} + \nu_2, \varphi_{1i}; \varphi + 2i \sim CAR(\mu_i, \sigma^2/n_i)$, distribuições a priori Normal para $\nu_1, \nu_2, \delta_{1i}, \mu^\rho$, com média zero e precisão 10^{-6} , distribuições a priori Gama Inversa para τ, τ^ρ .

O modelo ajustado difere do modelo geral (3), dado que as variáveis latentes não foram incluídas no modelo. A diferença é que a distribuição a priori condicional auto-regressiva foi associada aos parâmetros β 's. A tabela 6 mostra os valores esperados dos parâmetros, desvios-padrões e percentis, 5% e 95%. Pode-se confirmar que todos os parâmetros foram estatisticamente diferentes de zero.

As taxas de prêmio foram calculadas levando-se em conta os níveis de cobertura de 50 a 70% (Tab. 7).

Ressalta-se que o prêmio pago pelo produtor rural é municipalizado, ou seja, todos os produtores localizados em um mesmo município pagarão o mesmo valor para a seguradora. Nesse contexto, levando-se em conta a suposição de que todas as propriedades rurais adquirem seguro agrícola, o total de prêmios ganhos pela seguradora será dado pela multiplicação da taxa de prêmio pelo financiamento

Tabela 6: Parâmetros estimados, desvio-padrão e percentis.

Parâmetro	Município	Média	Desvio-padrão	5%	95%
β_0	C1	50,67	44,47	-5,42	105,3
	C2	47,65	41,64	-6,67	102,3
	C3	48,16	45,3	-7,43	102,8
	C4	48,3	42,72	-7,03	103,1
	C5	47,62	41,96	-7,79	103
	C6	53,86	61,3	-5,7	108,4
	C7	47,73	40,41	-7	101,9
	C8	53,82	56,43	-5,27	108,6
	C9	49,1	42,06	-6,39	104,5
	C10	48,56	42,36	-6,81	103
	C11	48,41	44,54	-6,52	102,8
	C12	48,38	41,42	-6,91	102,3
β_1	C1	-8,579	9,034	-22,61	6,035
	C2	-8,515	8,97	-22,53	6,19
	C3	-8,444	9,127	-22,57	6,5
	C4	-8,483	9,007	-22,45	6,355
	C5	-8,43	8,95	-22,45	6,292
	C6	-8,65	9,207	-22,94	6,158
	C7	-8,442	8,938	-22,39	6,254
	C8	-8,646	9,101	-22,83	6,177
	C9	-8,438	8,954	-22,39	6,321
	C10	-8,41	8,963	-22,42	6,269
	C11	-8,515	9,008	-22,55	6,251
	C12	-8,382	8,935	-22,33	6,265
δ_1	C1	2,19	1,021	0,552	3,857
	C2	1,99	1,052	0,259	3,73
	C3	1,94	1,191	0,011	3,901
	C4	2,217	1,201	0,308	4,173
	C5	1,989	1,254	-0,098	4,018
	C6	1,204	1,227	-0,799	3,173
	C7	2,659	1,212	0,672	4,674
	C8	2,343	1,194	0,423	4,364
	C9	2,125	1,321	0,015	4,371
	C10	1,889	1,142	0,049	3,751
	C11	3,814	1,347	1,649	6,109
	C12	2,053	1,173	0,243	3,9
ρ	C1	0,662	0,12	0,463	0,8553
	C2	0,701	0,129	0,491	0,9125
	C3	0,728	0,134	0,51	0,947
	C4	0,703	0,131	0,491	0,9107
	C5	0,756	0,13	0,549	0,9711
	C6	0,784	0,132	0,571	0,9934
	C7	0,628	0,142	0,395	0,8556
	C8	0,674	0,127	0,457	0,8729
	C9	0,759	0,134	0,534	0,9734
	C10	0,768	0,129	0,555	0,9748
	C11	0,569	0,134	0,344	0,7802
	C12	0,749	0,134	0,539	0,9586

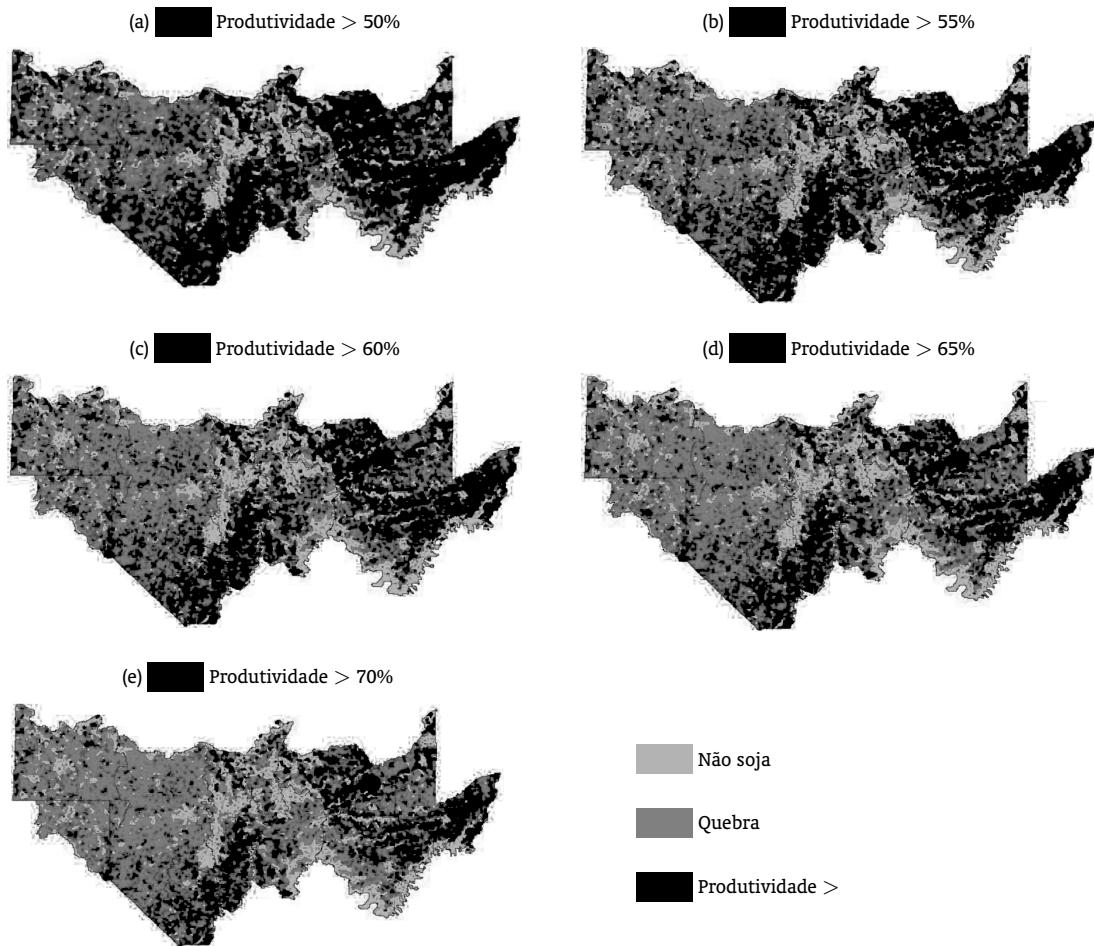
Fonte: Resultados da pesquisa.

**Tabela 7:** Taxas de prêmio por município para os níveis de cobertura de 50, 55, 60, 65 e 70%.

Municípios	LC %	PR %	Municípios	LC %	PR %
C1	50	3,857	C7	50	0,628
	55	4,114		55	0,696
	60	4,477	C7	60	0,844
	65	4,987		65	1,1
	70	5,71		70	1,526
C2	50	0,805	C8	50	2,282
	55	0,894		55	2,436
	60	1,043		60	2,688
	65	1,297		65	3,068
	70	1,718		70	3,628
C3	50	0,419	C9	50	0,001
	55	0,465		55	0,004
	60	0,571		60	0,014
	65	0,769		65	0,041
	70	1,112		70	0,124
C4	50	0,486	C10	50	0,001
	55	0,54		55	0,005
	60	0,639		60	0,021
	65	0,832		65	0,054
	70	1,176		70	0,143
C5	50	0,183	C11	50	0,241
	55	0,199		55	0,26
	60	0,239		60	0,308
	65	0,337		65	0,418
	70	0,539		70	0,624
C6	50	5,352	C12	50	0,016
	55	5,681		55	0,021
	60	6,104		60	0,037
	65	6,673		65	0,086
	70	7,44		70	0,216

Fonte: Resultados da pesquisa.

Figura 2: Mapas de produtividade para os municípios analisados ao nível de cobertura (a) 50%, (b) 55%, (c) 60%, (d) 65% e (e) 70%.



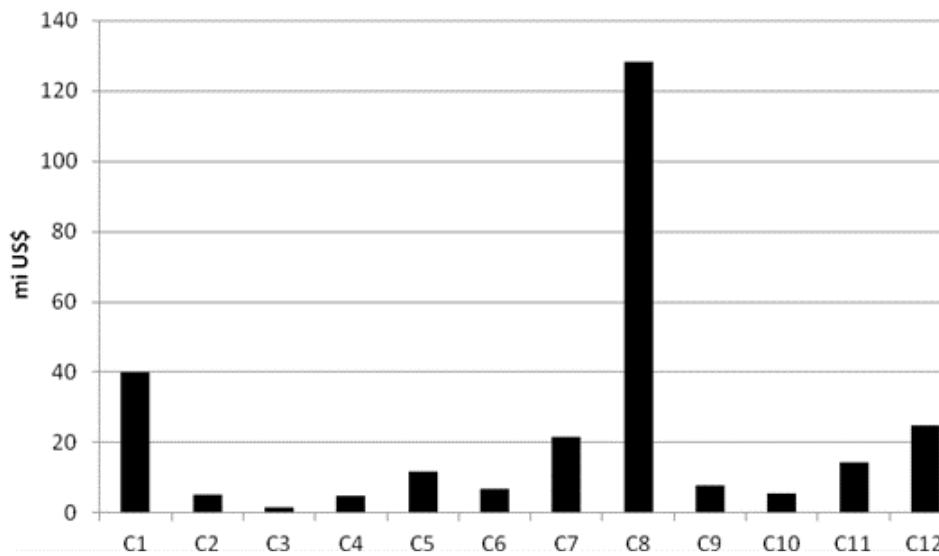
de custeio total de cada município. A figura 3 mostra o total do custeio utilizado por cada município na safra 2008/09.

O resultado líquido financeiro da safra 2008/09 será dado pela diferença entre o índice de perda e a taxa de prêmio, multiplicado pelo financiamento de custeio. A tabela 8 mostra os resultados associados a cada nível de cobertura.

Nota-se que, para todos os municípios, o índice de perda foi maior do que a taxa de prêmio. Por esse motivo, os prejuízos foram maiores do que o total ganho em prêmios nos municípios selecionados, para todos os níveis de cobertura. Ademais, percebe-se que os prejuízos aumentam à medida que o nível de cobertura aumenta.

Os prejuízos totais para os níveis de cobertura 50 a 70% foram, respectivamente, iguais a US\$ 99,6, US\$ 116,7, US\$ 132,4, US\$ 147,2 e US\$ 159,3 milhões. Em outras palavras, se a seguradora tivesse oferecido apenas contratos ao nível de 70% de cobertura, o prejuízo total teria sido igual a US\$ 159,3 milhões.

Observa-se que o município C8 (Palotina) apresentou o maior prejuízo líquido em função não apenas de seu elevado percentual de perda, mas também devido ao alto valor de financiamento contraído pelo

Figura 3: Financiamento de custeio, por município, em milhões de dólares.

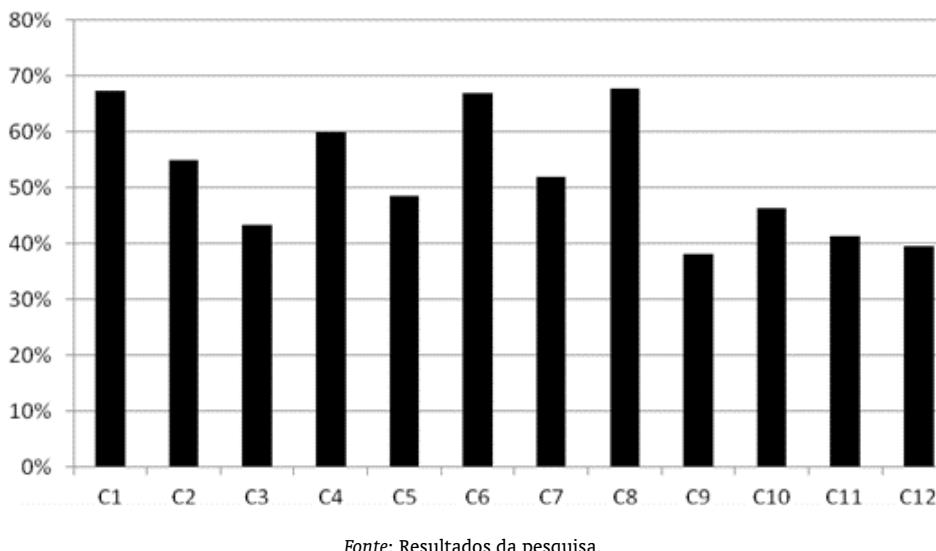
Obs.: Média das cotações de fechamento Ptax, referente ao período de agosto a outubro de 2008 (período de início de safra de verão – 01/08 a 31/10).

Fonte: Banco Central (2011).

Tabela 8: Perdas líquidas por município, em milhões de dólares, para cada nível de cobertura. *Obs.:* Média das cotações de fechamento Ptax, referente ao período de agosto a outubro de 2008 (período de início de safra de verão – 01/08 a 31/10).

Município	Nível de Cobertura				
	50	55	60	65	70
C1	19,5	22,4	25	27,1	29
C2	1	1,2	1,4	1,6	1,7
C3	0,2	0,3	0,3	0,4	0,4
C4	0,9	1,1	1,3	1,4	1,5
C5	1,9	2,3	2,8	3,3	3,8
C6	3,2	3,6	4	4,4	4,7
C7	4,9	6	7,2	8,4	9,5
C8	60	69,1	76,7	83,7	88,5
C9	0,9	1,2	1,6	2	2,4
C10	1	1,3	1,6	1,9	2,2
C11	2,5	3,2	4,2	5,1	6
C12	3,7	5	6,3	7,9	9,4

Fonte: Resultados da pesquisa.

Figura 4: Relação percentual entre prejuízos mínimos e máximos, por município.

Fonte: Resultados da pesquisa.

município. Ainda, para cada um dos municípios analisados, a relação entre perdas mínimas e máximas ficou entre 38% (C9) e 68% (C8), ou seja, em alguns municípios essa diferença não chega a 40%. Por outro lado, em outros municípios pode-se ter uma diferença de quase 70% (Fig. 4).

Isso mostra que as seguradoras devem ter cautela em relação ao nível de cobertura que ofertarão em regiões onde não existam informações suficientes para a quantificação e precificação do risco. A amplitude entre máximos e mínimos pode ser elevada dependendo do município.

Nesse contexto, em regiões de alto risco ou sem informações mais precisas sobre o perfil de risco, deve-se restringir a oferta de seguro com o mínimo de cobertura possível para evitar grandes prejuízos. Ademais, é essencial que as seguradoras tenham provisões suficientes para cobertura de catástrofes.

11. CONCLUSÃO

A pesquisa abordou dois aspectos fundamentais do seguro agrícola: estimativa da taxa de prêmio e quantificação das perdas agrícolas. No primeiro caso, o modelo escolhido apresentou uma estrutura temporal com uma componente estocástica e uma componente determinística, de tal forma que a correlação espacial foi captada pela distribuição a priori condicional auto-regressiva.

Na análise e precificação do risco, as seguradoras baseiam-se em informações passadas das perdas. Municípios com alta incidência de perdas recebem classificação alta de risco, e vice-versa. E, também, com base na série histórica se determina o preço do risco. Porém, o mercado desconhece a informação de produtividade do ano atual. O IBGE libera as informações de produtividade municipais defasadas em dois anos.

Dessa forma, a metodologia possibilita obter previsões da produtividade com maior precisão em um contexto caracterizado por séries históricas relativamente curtas para cada município. Por esse motivo, é fundamental incluir a informação dos municípios vizinhos na modelagem. Além disso, as informações de precipitação acumulada foram incorporadas na análise como uma média correspondente à segunda quinzena de janeiro até a primeira quinzena de março, período crítico para a soja na região de estudo.



Em termos financeiros, a taxa de prêmio está relacionada com a receita das seguradoras, ou seja, com o valor total dos prêmios ganhos pelas seguradoras durante a safra. Porém, ao longo do ciclo não se sabe ao certo qual será o nível de exposição da empresa. Em caso de sinistro, pode ser que as receitas sejam suficientes para cobrir os prejuízos (indenizações) em anos com clima favorável, ou insuficientes em anos com estiagens severas.

Nesse contexto, o monitoramento da safra torna-se essencial para a saúde financeira das seguradoras que operam no ramo rural. Com o monitoramento, é possível acompanhar o andamento das culturas de interesse e antever prejuízos que podem comprometer a carteira agrícola. Ademais, com informações antecipadas de eventuais sinistros, a seguradora ou a empresa prestadora de serviços podem dimensionar com maior tempo e menor custo o contingente de peritos que realizarão a regulação de sinistro. Em função do curto período de tempo previsto na legislação para a regulação, as empresas necessitam de uma logística eficiente.

Em diversos casos, é comum os peritos visitarem fazendas de dois mil hectares em alguns estados. Nesse caso, o tamanho da propriedade torna-se também um problema para a regulação. Nesses casos, em geral, o regulador não consegue visitar mais do que uma propriedade por vez, aumentando consideravelmente o número de peritos necessários para cobrir uma grande área dentro do prazo estipulado pela legislação.

O estudo contribui para um melhor entendimento da dinâmica das perdas agrícolas e de suas implicações para o mercado segurador e agentes creditícios, além de utilizar uma forma alternativa de precificação. Com as imagens de satélite, foi possível localizar as áreas de soja e quantificar as perdas durante a safra.

As perdas totais foram calculadas para cada nível de cobertura, bem como o ganho total de prêmios, resultando em um valor monetário líquido. Ressalta-se que, até o momento, a grande maioria dos estudos em seguro agrícola concentra-se em discutir metodologias de precificação e modelagem estatística da produtividade agrícola. Pouco se discute sobre metodologias para acompanhar e antecipar prejuízos agrícolas e suas implicações para o mercado segurador e financeiro. Deve-se destacar que o mapeamento da área plantada e o acompanhamento das lavouras são fundamentais também para a formulação de políticas agrícolas e para o setor de insumos, máquinas e implementos, defensivos, entre outros.

Apesar de apresentar resultados precisos, o estudo baseia-se em uma série de pressuposições que podem ser relaxadas de tal forma a generalizar os resultados para os casos em que existam perdas parciais, focar apenas nas fazendas (ou grupo de fazendas) seguradas dentro de um município e estabelecer franquias diferentes de zero.

Por fim, o desenvolvimento do seguro agrícola no Brasil passa pelo aprimoramento das informações que podem estar disponíveis ao mercado e ao governo, sejam elas de natureza climática, agronômica ou espectral. Quanto maior o número de informações desagregadas em um alto nível de detalhamento, maior a possibilidade de se ofertar produtos que atendam às expectativas dos produtores rurais e agentes econômicos envolvidos no agronegócio.

BIBLIOGRAFIA

- Alexandridis, T. K., Gitas, I. Z., & Silleos, N. G. (2008). An estimation of the optimum temporal resolution for monitoring vegetation condition on a nationwide scale using MODIS/Terra data. *International Journal of Remote Sensing*, 29(12):3589–3607.
- Anibal, M. E. (1989). Estimation of crop yield variation and its use in farm financial planning. Technical report, Michigan State University, Department of Agricultural, Food, and Resource Economics. Graduate Research Master's Degree Plan B Papers.

- Atwood, J., Shaik, S., & Watts, M. (2002). Can normality of yields be assumed for crop insurance? *Canadian Journal of Agricultural Economics/Revue canadienne d'agroéconomie*, 50(2):171–184.
- Atwood, J., Shaik, S., & Watts, M. (2003). Are crop yields normally distributed? A reexamination. *American Journal of Agricultural Economics*, 85(4):888–901.
- Bernardinelli, L., Clayton, D., & Montomoli, C. (1995). Bayesian estimates of disease maps: how important are priors? *Statistics in Medicine*, 14(21-22):2411–2431.
- Besag, J. (1974). Spatial interaction and the statistical analysis of lattice systems. *Journal of the Royal Statistical Society. Series B (Methodological)*, p. 192–236.
- Besag, J., York, J., & Mollié, A. (1991). Bayesian image restoration, with two applications in spatial statistics. *Annals of the Institute of Statistical Mathematics*, 43(1):1–20.
- Carlin, B. P. & Louis, T. A. (2000). *Bayes and empirical Bayes methods for data analysis*, volume 17. Boca Raton, FL: Chapman & Hall/CRC.
- Chen, S. L. & Miranda, M. (2004). Modeling multivariate crop yield densities with frequent extreme events. Paper presented at AAEA meeting, Denver, Colorado.
- Clayton, D. & Kaldor, J. (1987). Empirical Bayes estimates of age-standardized relative risks for use in disease mapping. *Biometrics*, 43:671–681.
- Cressie, N. & Chan, N. H. (1989). Spatial modeling of regional variables. *Journal of the American Statistical Association*, 84(406):393–401.
- Davis, P. A., Breed, C. S., McCauley, J. F., & Schaber, G. G. (1993). Surficial geology of the Safsaf region, south-central Egypt, derived from remote-sensing and field data. *Remote Sensing of Environment*, 46(2):183–203.
- Day, R. H. (1965). Probability distributions of field crop yields. *Journal of Farm Economics*, 47(3):713–741.
- Dreassi, E. (2003). Space-time analysis of the relationship between material deprivation and mortality for lung cancer. *Environmetrics*, 14(5):511–521.
- Duarte, V. (1988). Fiscalização de propriedades agrícolas por satélite - Fase I. In *Simpósio Brasileiro de Sensoriamento Remoto*, 5, Natal, Anais, volume 1. São José dos Campos: INPE, p. 217–221.
- Ferencz, C., Bognar, P., Lichtenberger, J., Hamar, D., Tarcsai, G., Timar, G., Molnár, G., Pásztor, S., Steinbach, P., Szekely, B., Ferencz, O., & Ferencz-Árkos, I. (2004). Crop yield estimation by satellite remote sensing. *International Journal of Remote Sensing*, 25(20):4113–4149.
- Finger, R. (2010). Revisiting the evaluation of robust regression techniques for crop yield data detrending. *American Journal of Agricultural Economics*, 92(1):205–211.
- Fischer, A. (1994). A simple model for the temporal variations of NDVI at regional scale over agricultural countries, validation with ground radiometric measurements. *International Journal of Remote Sensing*, 15(7):1421–1446.
- Gallagher, P. (1987). US soybean yields: estimation and forecasting with nonsymmetric disturbances. *American Journal of Agricultural Economics*, 69:796–803.
- Gelfand, A. E. & Ghosh, S. K. (1998). Model choice: a minimum posterior predictive loss approach. *Biometrika*, 85(1):1–11.



- Gelfand, A. E., Ghosh, S. K., Knight, J. R., & Sirmans, C. F. (1998). Spatio-temporal modeling of residential sales data. *Journal of Business & Economic Statistics*, 16(3):312–321.
- Goodwin, B. K. (2001). Problems with market insurance in agriculture. *American Journal of Agricultural Economics*, 83(3):643–649.
- Goodwin, B. K. & Ker, A. P. (1998). Nonparametric estimation of crop yield distributions: implications for rating group-risk crop insurance contracts. *American Journal of Agricultural Economics*, 80(1):139–153.
- Göpfert, H., Rossetti, L., & Souza, J. (1993). Eventos generalizados e segurança agrícola. Brasília: IPEA.
- Granados-Ramírez, R., Reyna-Trujillo, T., Gómez-Rodríguez, G., & Soria-Ruiz, J. (2004). Analysis of NOAA-AVHRR-NDVI images for crops monitoring. *International Journal of Remote Sensing*, 25(9):1615–1627.
- Groten, S. (1993). NDVI-crop monitoring and early yield assessment of Burkina Faso. *International Journal of Remote Sensing*, 14(8):1495–1515.
- Harri, A., Erdem, C., Coble, K. H., & Knight, T. O. (2008). Crop yield distributions: A reconciliation of previous research and statistical tests for normality. *Review of Agricultural Economics*, 31(1):163–182.
- Henderson, J. V., Storeygard, A., & Weil, D. N. (2012). Measuring economic growth from outer space. *The American Economic Review*, 102(2):994–1028.
- Hubner, O. (2009). Soja. Safra 08/09 Estado do Paraná, Secretaria da Agricultura e do Abastecimento, Departamento de Economia Rural.
- Huete, A., Didan, K., Miura, T., Rodriguez, E. P., Gao, X., & Ferreira, L. G. (2002). Overview of the radiometric and biophysical performance of the MODIS vegetation indices. *Remote Sensing of Environment*, 83(1):195–213.
- Jensen, J. R. (2000). *Remote sensing of the environment: An earth resource perspective*. Prentice Hall.
- Junges, A. H., Alves, G., & Fontana, D. C. (2007). Estudo indicativo do comportamento do NDVI e EVI em lavouras de cereais de inverno da região norte do Estado do Rio Grande do Sul, através de imagens MODIS. In *Anais XIII Simpósio Brasileiro de Sensoriamento Remoto*, Florianópolis, Brasil. p. 241–248.
- Just, R. E. & Weninger, Q. (1999). Are crop yields normally distributed? *American Journal of Agricultural Economics*, 81(2):287–304.
- Kapiamba, L. F. (2005). Modeling heteroskedasticity of crop yield distributions: implications for normality. In *Annual Meeting of the American Agricultural Economics Association*, p. 24–27.
- Ker, A. P. & Coble, K. (2003). Modeling conditional yield densities. *American Journal of Agricultural Economics*, 85:291–304.
- Ker, A. P. & Goodwin, B. K. (2000). Nonparametric estimation of crop insurance rates revisited. *American Journal of Agricultural Economics*, 83(2):463–478.
- Laud, P. W. & Ibrahim, J. G. (1995). Predictive model selection. *Journal of the Royal Statistical Society. Series B (Methodological)*, 57:247–262.
- Macedo, M. & Rudorff, B. (2003). Geotecnologias no seguro agrícola do milho safrinha. *Agricultura São Paulo*, 50:43–52.
- Melo, R., Fontana, D., Berlato, M., & Ducati, J. (2008). An agrometeorological-spectral model to estimate soybean yield, applied to southern Brazil. *International Journal of Remote Sensing*, 29(14):4013–4028.

- Miranda, M. J. & Glauber, J. W. (1997). Systemic risk, reinsurance, and the failure of crop insurance markets. *American Journal of Agricultural Economics*, 79(1):206–215.
- Moss, C. B. & Shonkwiler, J. S. (1993). Estimating yield distributions with a stochastic trend and nonnormal errors. *American Journal of Agricultural Economics*, 75(4):1056–1062.
- Murthy, C., Sesha Sai, M., Chandrasekar, K., & Roy, P. (2009). Spatial and temporal responses of different crop-growing environments to agricultural drought: a study in Haryana state, India using NOAA AVHRR data. *International Journal of Remote Sensing*, 30(11):2897–2914.
- Navalgund, R. R., Jayaraman, V., & Roy, P. S. (2007). Remote sensing applications: An overview. *Current Science*, 93:1747–1766.
- Nelson, C. H. & Preckel, P. V. (1989). The conditional beta distribution as a stochastic production function. *American Journal of Agricultural Economics*, 71(2):370–378.
- Nemani, R., Pierce, L. L., Running, S. W., & Goward, S. N. (1993). Developing satellite-derived estimates of surface moisture status. *Journal of Applied Meteorology*, 32(3):548–557.
- Norwood, B., Roberts, M. C., & Lusk, J. L. (2004). Ranking crop yield models using out-of-sample likelihood functions. *American Journal of Agricultural Economics*, 86(4):1032–1043.
- Norwood, F. B., Roberts, M. C., & Lusk, J. L. (2006). Reply: Ranking crop yield models. *American Journal of Agricultural Economics*, 88(4):1111–1112.
- Ozaki, V. A., Ghosh, S. K., Goodwin, B. K., & Shirota, R. (2008a). Spatio-temporal modeling of agricultural yield data with an application to pricing crop insurance contracts. *American Journal of Agricultural Economics*, 90(4):951–961.
- Ozaki, V. A., Goodwin, B. K., & Shirota, R. (2008b). Parametric and nonparametric statistical modelling of crop yield: implications for pricing crop insurance contracts. *Applied Economics*, 40(9):1151–1164.
- Ozaki, V. A. & Silva, R. S. (2009). Bayesian ratemaking procedure of crop insurance contracts with skewed distribution. *Journal of Applied Statistics*, 36(4):443–452.
- Pax-Lenney, M. & Woodcock, C. E. (1997). The effect of spatial resolution on the ability to monitor the status of agricultural lands. *Remote Sensing of Environment*, 61(2):210–220.
- Quarmby, N., Milnes, M., Hindle, T., & Silleos, N. (1993). The use of multi-temporal NDVI measurements from AVHRR data for crop yield estimation and prediction. *International Journal of Remote Sensing*, 14(2):199–210.
- Ramírez, O. A. (1997). Estimation and Use of Multivariate Parametric Model for Simulating Heteroscedastic, Correlated, Non-normal Random Variables: The Case of Corn Belt Corn, Soybean and Wheat Yields. *American Journal of Agricultural Economics*, 79:291–305.
- Ramírez, O. A. & McDonald, T. U. (2006). The expanded Johnson system: a highly flexible crop yield distribution model. Paper presented at the American Economics Association 2006 Annual Meeting.
- Ramírez, O. A., Misra, S., & Field, J. (2003a). Crop-yield distributions revisited. *American Journal of Agricultural Economics*, 85(1):108–120.
- Ramírez, O. A., Misra, S. K., & Nelson, J. (2003b). Efficient estimation of agricultural time series models with nonnormal dependent variables. *American Journal of Agricultural Economics*, 85(4):1029–1040.



- Rasmussen, M. S. (1992). Assessment of millet yields and production in northern Burkina Faso using integrated NDVI from the AVHRR. *International Journal of Remote Sensing*, 13(18):3431–3442.
- Rosa, R. (1990). *Introdução ao sensoriamento remoto*. Uberlândia: EDEFU.
- Rouse Jr, J., Haas, R., Schell, J., & Deering, D. (1974). Monitoring vegetation systems in the Great Plains with ERTS. *Third ERTS Symposium, NASA SP-351*, I:309–317.
- Rudorff, B. & Batista, G. (1989). *Relatório da fase II do Projeto Estima – Dados Landsat-TM e agrometeorológicos na estimativa da produtividade da cultura do trigo ao nível de propriedades rurais*. São José dos Campos: INPE. 50 p., (INPE-4782-RPE/582).
- Salazar, L., Kogan, F., & Roytman, L. (2007). Use of remote sensing data for estimation of winter wheat yield in the United States. *International Journal of Remote Sensing*, 28(17):3795–3811.
- Sherrick, B. J., Zanini, F. C., Schnitkey, G. D., & Irwin, S. H. (2004). Crop insurance valuation under alternative yield distributions. *American Journal of Agricultural Economics*, 86(2):406–419.
- Silleos, N., Perakis, K., & Petsanis, G. (2002). Assessment of crop damage using space remote sensing and GIS. *International Journal of Remote Sensing*, 23(3):417–427.
- Swinton, S. M. & King, R. P. (1991). Evaluating robust regression techniques for detrending crop yield data with nonnormal errors. *American Journal of Agricultural Economics*, 73(2):446–451.
- Taylor, C. R. (1990). Two practical procedures for estimating multivariate nonnormal probability density functions. *American Journal of Agricultural Economics*, 72(1):210–217.
- Turvey, C. & Zhao, J. (1999). *Parametric and non-parametric crop yield distributions and their effects on all-risk crop insurance premiums*. Department of Agricultural Economics and Business, University of Guelph.
- Vicente-Serrano, S. M., Cuadrat-Prats, J. M., & Romo, A. (2006). Early prediction of crop production using drought indices at different time-scales and remote sensing data: application in the Ebro Valley (north-east Spain). *International Journal of Remote Sensing*, 27(3):511–518.
- Wall, L., Larocque, D., & Léger, P.-M. (2008). The early explanatory power of NDVI in crop yield modelling. *International Journal of Remote Sensing*, 29(8):2211–2225.
- Waller, L. A., Carlin, B. P., Xia, H., & Gelfand, A. E. (1997). Hierarchical spatio-temporal mapping of disease rates. *Journal of the American Statistical Association*, 92(438):607–617.
- Wang, H. & Zhang, H. (2003). On the possibility of a private crop insurance market: A spatial statistics approach. *Journal of Risk and Insurance*, 70:111–124.
- Woodard, J. D. & Garcia, P. (2008). Weather derivatives, spatial aggregation, and systemic risk: implications for reinsurance hedging. *Journal of Agricultural and Resource Economics*, 33:34–51.
- Yang, S.-R., Koo, W. W., & Wilson, W. W. (1992). Heteroskedasticity in crop yield models. *Journal of Agricultural and Resource Economics*, 17:103–109.